

扩散策略：基于动作扩散的视觉-运动策略学习

作者：程驰^{1*}，徐振佳¹，冯思远²，Eric Cousineau²，杜一伦³，Benjamin Burchfiel²，Russ Tedrake^{2,3}，宋舒然^{1,4}

¹ 哥伦比亚大学，² MIT，³ MIT CSAIL，⁴ Allen Institute for AI

* 共同一作

可以是其它 observation

摘要

本文提出了扩散策略（Diffusion Policy）——一种将机器人视觉-运动策略建模为条件去噪扩散过程的新方法。我们在 4 个机器人操作基准集上的 15 项不同任务中对扩散策略进行了系统评测，发现其性能一致优于现有最先进策略，平均提升达 46.9%。

扩散策略通过学习动作分布的得分函数梯度（score function gradient），并在推理阶段通过一系列随机 Langevin 动力学步骤迭代优化该梯度场来生成动作。我们发现，扩散框架在机器人策略中具有显著优势：

- 能够优雅处理多模态动作分布；
- 适用于高维动作空间；
- 展现出卓越的训练稳定性。

为充分发挥扩散模型在物理机器人视觉-运动策略学习中的潜力，本文提出若干关键技术贡献，包括：

- 滚动时域控制（receding horizon control）的融合；
- 视觉条件化机制（visual conditioning）；
- 时序扩散 Transformer（Time-series Diffusion Transformer）。

我们希望本工作能激发新一代策略学习方法，充分利用扩散模型强大的生成建模能力。

代码、数据与训练细节公开于：diffusion-policy.cs.columbia.edu

关键词：模仿学习、视觉-运动策略、操作控制

1 引言

从示教中学习策略（Policy Learning from Demonstration），最简形式可视为将观测映射到动作的监督回归任务。然而，机器人动作预测的独特性质——如多模态分布、时序相关性、高精度要求等——使其显著区别于常规监督学习问题，极具挑战。

已有工作尝试通过不同方式应对该挑战：

- 改变动作表示形式（图1a）：如高斯混合模型（Mandlekar et al., 2021）、离散化动作的分类表示（Shafiullah et al., 2022）；
- 转换策略表示范式（图1b）：从显式策略转向隐式策略（如能量模型），以更好捕捉多模态性（Florence et al., 2021; Wu et al., 2020）。

本文提出一种全新的机器人视觉-运动策略：扩散策略，即在机器人动作空间上执行“条件去噪扩散过程”（Ho et al., 2020；见图1c）。该策略不直接输出动作，而是以视觉观测为条件，迭代 K 步推断动作得分梯度场并优化之。

该范式使机器人策略自然继承扩散模型的关键优势：

- 表达多模态动作分布：通过学习动作得分函数梯度，并在其梯度场上执行随机 Langevin 动力学采样，扩散策略可表达任意可归一化分布（含多峰分布），克服策略学习中的经典难题。
- 适应高维输出空间：扩散模型在图像生成中展现的高维扩展性，使其可联合预测未来动作序列（而非单步动作），从而增强动作时序一致性，避免短视规划。
- 训练稳定：能量模型策略需负采样估计难解归一化常数，导致不稳定（Du et al., 2020; Florence et al., 2021）；扩散策略通过学习梯度场绕过此问题，在保持分布表达力的同时实现稳定训练。

本文主贡献是将上述优势引入机器人领域，并在复杂真实操作任务中验证其有效性。为成功应用扩散模型于视觉-运动策略学习，我们提出以下关键技术：

- 闭环动作序列预测：结合动作序列预测与滚动时域控制，实现鲁棒执行——策略可持续重规划以保持响应性，同时维持动作时序一致性。
- 视觉条件化：将视觉观测视为条件变量（而非联合分布一部分）。该设计使策略仅需一次提取视觉表征（无需每步重复），显著降低计算开销，支持实时动作推理。
- 时序扩散 Transformer：提出新型 Transformer 扩散网络，缓解 CNN 的过平滑问题，在高频动作变化与速度控制任务中达到 SOTA。

我们系统评测了扩散策略在 4 个基准（Florence et al., 2021; Gupta et al., 2019; Mandlekar et al., 2021; Shafiullah et al., 2022）共 15 项任务的表现——涵盖仿真/真实环境、2–6 自由度动作、单/多任务、全/欠驱动系统、刚体/流体对象、单/多人示教数据。

实验表明：所有任务性能均显著提升（平均 +46.9%），有力验证扩散策略的有效性。

本文为会议论文（Chi et al., 2023）的扩展版，新增：

- 与控制理论的关联讨论（§4.5）；
- 关于网络架构、预训练/微调范式的补充消融实验（§5.4）；
- 三项双臂操作任务（打蛋器、铺垫子、叠衬衫）的真实实验（§7）。

2 扩散策略形式化

我们将视觉-运动策略建模为去噪扩散概率模型 (DDPM, Ho et al., 2020)。
其核心优势：① 可表达复杂多模态动作分布；② 训练稳定——几乎无需任务特调超参。

2.1 去噪扩散概率模型 (DDPM)

DDPM 是一类生成模型，将输出生成视为去噪过程（亦称随机 Langevin 动力学, Welling & Teh, 2011）。
从高斯噪声 $x_K \sim \mathcal{N}(0, I)$ 出发，DDPM 迭代 K 步逐步去噪：

$$x_{k-1} = \alpha(x_k - \gamma \epsilon_\theta(x_k, k) + \mathcal{N}(0, \sigma^2 I))$$

其中 ϵ_θ 为带参噪声预测网络， x, γ, σ 为迭代步 k 相关的调度超参（详见 §3.3）。

该式可理解为单步含噪梯度下降：

$$x' = x - \gamma \nabla E(x)$$

即 $\epsilon_\theta(x, k)$ 预测能量函数梯度场 $\nabla E(x)$ 。

2.2 DDPM 训练

训练流程：

- 1. 从数据集随机采样干净样本 x_0 ；
- 2. 随机选择去噪步 k ，按对应方差采样噪声 ϵ_k ；
- 3. 将噪声加至 x_0 得 $x_k = x_0 + \epsilon_k$ ；
- 4. 训练 ϵ_θ 预测噪声：

$$\mathcal{L} = \text{MSE}(\epsilon_k, \epsilon_\theta(x_k, k))$$

最小化该损失等价于最小化数据分布 $p(x_0)$ 与生成分布 $q(x_0)$ 之间的 KL 散度变分下界（Ho et al., 2020）。

2.3 用于视觉-运动策略学习的 DDPM 改编

标准 DDPM 用于图像生成（ x 为图像），我们将其适配机器人策略，需两大改动：

- 1. 输出变量替换：将 x 改为机器人动作序列；
- 2. 引入观测条件：使去噪过程条件于输入观测 O_t （见图2）。

闭环动作序列预测

策略输入：最新 T_o 步观测 O_t ；
输出：未来 T_p 步动作 A_t ；
执行：前 T_a 步动作（无重规划）→ 下时刻以剩余动作作热身启动重规划。

• T_o ：观测时域； T_p ：动作预测时域； T_a ：动作执行时域。
• 优势：动作时序一致性 + 外部扰动响应性。

视觉观测条件化

我们用 DDPM 近似条件分布 $p(A_t | O_t)$ 而非联合分布 $p(A_t, O_t)$ ，即：

$$A_t^{k-1} = \alpha(A_t^k - \gamma \epsilon_\theta(O_t, A_t^k, k) + \mathcal{N}(0, \sigma^2 I))$$

对应训练损失：

$$\mathcal{L} = \text{MSE}(\epsilon_k, \epsilon_\theta(O_t, A_t^0 + \epsilon_k, k))$$

该设计大幅提升推理速度，支持视觉编码器端到端训练。

3 关键设计决策

3.1 网络架构选择

我们对比两类主干：

- CNN 扩散策略：
采用 1D 时序 CNN（Janner et al., 2022b），改进点：
① 用 FiLM（特征线性调制）将观测编码 O_t 注入卷积层；
② 仅预测动作轨迹（非观测-动作联合）；
③ 移除目标状态修复条件（与滚动预测不兼容）。
适用场景：多数任务即插即用，但对高频动作变化（如速度控制）表现差（CNN 偏好低频信号）。
- 时序扩散 Transformer：
改进 minGPT（Shafiuallah et al., 2022）Transformer 架构：
• 动作嵌入 A_t^k + 扩散步嵌入 k 作输入 Token；
• 观测 O_t 经 MLP 映射为嵌入序列 → 注入解码器跨注意力层；

- 每层输出 Token 预测对应动作梯度 ε_θ 。
- 优势：缓解 CNN 过平滑，适合高动态任务；缺点：超参更敏感。

建议：新任务首选 CNN 扩散策略；若性能不足（任务复杂/动作高频），再尝试 Transformer 并调参。

3.2 视觉编码器

- 主干：ResNet-18（无预训练）；
- 改进：
 - ① 全局平均池化 → 空间 Softmax 池化（保留空间信息）；
 - ② BatchNorm → GroupNorm（与 DDPM 常用 EMA 兼容以保稳定）。
- 多视角：各相机独立编码 → 时序拼接为 O_t 。

3.3 噪声调度

采用 Square Cosine 噪声调度（DDPM, Nichol & Dhariwal 2021），经验表明其对动作信号高频/低频成分平衡最佳。

3.4 实时推理加速

采用 DDIM（Song et al., 2021）：解耦训练/推理步数。
实测：100 训练步 + 10 推理步 → NVIDIA 3080 上延迟 0.1 秒。

4 扩散策略的若干特性

4.1 多模态动作分布建模

多模态源于：① 随机初始化 $A_t^K \sim \mathcal{N}(0, I)$ → 不同收敛盆；② 迭代加噪 → 跨模态迁移（图3示例）。

4.2 与位置控制的协同性

意外发现：扩散策略在位置控制下显著优于速度控制（图4），与多数现有工作（偏爱速度控制）相反。
原因推测：

- ① 位置控制本身多模态性更显著 → 扩散策略优势放大；
- ② 位置控制累积误差更小 → 更适配动作序列预测。

4.3 动作序列预测的优势

- 时序一致性：避免单步预测下连续动作跨模态切换导致抖动（图3）；
- 抗“空闲动作”干扰：示教中暂停产生的恒定/零速动作，易使单步策略过拟合并卡顿；序列预测可自然跳过。

4.4 训练稳定性

隐式策略（如 IBC）需负采样估计归一化常数 $Z(o, \theta)$ ，导致训练不稳定（图6）。
扩散策略直接建模得分函数梯度：

$$\nabla_a \log p(a \mid o) = -\nabla_a E_\theta(a, o) \approx -\varepsilon_\theta(a, o)$$

（与 Z 无关）→ 训练/推理均无需估计 Z → 高度稳定。

4.5 与控制理论的关联

简化情形：线性系统 + 线性反馈策略（如 LQR）→ 扩散策略最优去噪器为 $\varepsilon_\theta(s, a, k) = \frac{1}{\sigma_k}(a + Ks)$ ，DDIM 推理收敛至 $a = -Ks$ 。
启示：完美克隆行为需隐式学习（任务相关）动力学模型（Subramanian & Mahajan, 2019）。

5 评测

5.1 仿真环境与数据集

- Robomimic（9 任务变体）：5 任务 ×（单/多操作员示教）；
- Push-T（IBC 基准）：推 T 形块至目标（RGB 或关键点观测）；
- Multimodal Block Pushing（BET 基准）：顺序推两方块（长程多模态）；
- Franka Kitchen：操作 7 物体完成 4 任务（任意顺序，长/短程多模态）。

5.2 评测方法

- 指标：成功率（Push-T 用目标覆盖 IoU）；
- 评估：3 种子 × 50 初始态 → 150 轮滚；
- 报告：最佳 checkpoint / 最后 10 轮均值；
- 时长：状态策略 4500 轮；视觉策略 3000 轮。

5.3 关键发现

特性	结果
短程多模态	Push-T 中扩散策略等概率选左/右绕行；IBC/LSTM-GMM 偏向单侧；BET 无法坚持单模态

特性	结果
长程多模态	Block Push p2（推两块）↑32%；Kitchen p4（操作4物）↑213%
位置控制优势	显著优于速度控制（图4）；基线则相反
动作时域权衡	$T_a = 8$ 最优：过短 → 抖动；过长 → 响应迟钝（图5左）
抗延迟鲁棒性	位置控制可容忍 ≤4 步延迟（图5右）；速度控制更敏感
训练稳定性	超参跨任务一致；IBC 波动大（图6）

5.4 消融实验：视觉编码器

架构 & 预训练	从零训练	冻结预训练	微调 (LR=0.1×)
ResNet-18 (ImageNet21k)	0.94	0.58	0.92
ResNet-34 (ImageNet21k)	0.92	0.40	0.94
ViT-B/16 (CLIP)	0.22	0.70	0.98

结论：端到端训练或微调（小 LR）最佳；冻结预训练性能差 → 扩散策略需定制视觉表征。

6 真实世界评测

6.1 真实 Push-T

- 难点：① 两阶段（推块 → 归位）；② 精细调整多模态；③ 成功标准为最终 IoU（非过程最大值）。
- 结果（表6）：
 - 扩散策略（端到端）：**95% 成功率**，IoU=0.80（人类 0.84）；
 - IBC / LSTM-GMM：全失败（0%/20%）。
- 抗干扰（图8）：
 - ① 视觉遮挡 3 秒 → 略抖动仍完成；
 - ② 推程中块位移 → 立即反向重推；
 - ③ 归位时块位移 → 中断归位 → 重推 → 再归位（生成未见行为！）。

6.2 杯子翻转（6DoF Mug Flipping）

- 多模态：抓取/推动、正/反手抓、绕轴微调 → 基线全失败；
- 扩散策略：90% 成功率；可自主组合多推动/重抓（未示教）。

6.3 酱料倾倒与涂抹

任务	人类 (IoU/覆盖率)	LSTM-GMM	扩散策略
倾倒	0.79 / 100%	0.06 / 0%	0.74 / 79%
涂抹	0.79 / 100%	0.27 / 0%	0.77 / 100%

- LSTM-GMM 失败原因：倾倒后不抬勺；涂抹直接举勺（未接触酱料）。
- 扩散策略：优雅处理空闲动作（舀酱静待）、周期运动（螺旋涂抹）、外部扰动（移动面团）。

7 真实双臂任务

无需调参即用！

- 观测/动作扩展：双臂位姿+夹爪宽度；双场景+双腕相机。
- 示教方式：
 - VR（Quest Pro）→ 铺垫子、叠衬衫；
 - 双 Haption 力反馈设备 → 打蛋器（无反馈时 0/10 示教成功；有反馈 10/10）。

任务	示例	成功率	主失败模式
打蛋器	推碗 → 取器 → 入碗 → 握柄 → 摇柄	55%	初始位姿超域；握柄失败
铺垫子	抓边 → 提起 → 展开 → 居中	75%	初始抓取失败 → 循环卡住
叠衬衫	折袖×2 → 拖近 → 对折 → 抚平	75%	折袖失败；终态无法停止微调

8 相关工作

- 显式策略：直接回归（Pomerleau, 1988）或分类（Zeng et al., 2021）→ 难建模多模态；
- 隐式策略：能量模型（Florence et al., 2021）→ 多模态但训练不稳；
- 扩散模型应用：
 - 规划：Janner et al. (2022a) · Huang et al. (2023)；
 - RL：Wang et al. (2022)；

。本文定位：**行为克隆下的视觉-运动端到端策略** → 强调闭环、实时性、真实机器人适配。

9 局限与未来工作

- **局限 1**：继承行为克隆缺陷——依赖高质量示教；→ 可结合 RL 利用次优数据；
- **局限 2**：计算开销高（vs. LSTM-GMM）；→ 探索加速方法：新型噪声调度（Chen, 2023）、求解器（Karras et al., 2022）、一致性模型（Song et al., 2023）。

10 结论

本文系统验证扩散策略在机器人行为学习中的可行性：

- 15 项任务（仿真+真实）性能全面领先（+46.9%）；
- 训练稳定、易复现；
- 关键设计因子：滚动动作预测、末端位置控制、高效视觉条件化。

我们指出：**策略结构本身是行为克隆的性能瓶颈**。期望本工作推动学界探索扩散策略，并全面审视策略学习各环节（不限于数据）。

致谢 & 资助

丰田研究院、NSF CMMI-2037101 / IIS-2132519；Google（UR5 硬件支持）。

附录 A–D（实现细节、超参、任务设置、双臂任务初/终态图）因篇幅未展开，如需可提供专项翻译。

是否需要：

- 任一章节的 **LaTeX 排版原文**？
- 关键图表（如图3 多模态对比、图4 位置/速度控制、图8 鲁棒性）的**图文详解**？
- 扩散策略 **PyTorch 实现伪代码** 或 **与 PPO/SAC 对比分析**？
请随时指示。